

# Análisis de Regresión Logística

**1<sup>st</sup> Mauricio Campos**

*Inteligencia Artificial Gr2*

*Instituto Tecnológico de Costa Rica*

Cartago, Costa Rica

maucampos@estudiantec.cr

**2<sup>nd</sup> Ian Murillo**

*Inteligencia Artificial Gr2*

*Instituto Tecnológico de Costa Rica*

Cartago, Costa Rica

ianmurillo1234@estudiantec.cr

**3<sup>rd</sup> Mariana Quesada**

*Inteligencia Artificial Gr2*

*Instituto Tecnológico de Costa Rica*

Cartago, Costa Rica

marianaqsd@estudiantec.cr

**Abstract**—This paper presents the implementation and analysis of a logistic regression model using the PyTorch library, applied to the binary classification problem of predicting wine quality as either “good” or “bad”. The study includes an exploratory data analysis (EDA) to identify and justify the most relevant features, followed by the development of a logistic regression model trained under multiple hyperparameter configurations to assess its performance and robustness against potential overfitting. The evaluation was conducted using standard classification metrics such as accuracy, precision, recall, F1-Score, and AUC, along with confusion matrices for model validation. A comparative analysis of ten training experiments was performed, leading to the selection of the most suitable model. The results highlight both the strengths and limitations of logistic regression in this context and provide insights into its applicability for similar supervised learning problems.

## I. INTRODUCTION

La evaluación de la calidad del vino es una tarea crítica en la industria de alimentos y bebidas, ya que influye directamente en la satisfacción del consumidor y en el valor de mercado. Tradicionalmente, este proceso se ha basado en paneles de catadores expertos que, aunque efectivos, son subjetivos y requieren muchos recursos. En los últimos años, las técnicas de aprendizaje automático se han adoptado cada vez más para abordar este desafío, permitiendo una predicción de calidad automatizada, consistente y escalable basada en mediciones fisicoquímicas. El problema puede formularse como una tarea de clasificación binaria, donde los vinos se categorizan como de buena o mala calidad dependiendo de su composición química.

Varios autores han investigado este problema utilizando un enfoque de árboles de decisión. Con esa propuesta, se han demostrado fuertes capacidades predictivas en el conjunto de datos de calidad del vino de UCI, ofreciendo modelos interpretables aunque complejos. Más recientemente, se han empleado arquitecturas de redes neuronales y métodos de ensamblaje para lograr mayor precisión, a costa de un mayor costo computacional y una menor interpretabilidad. La regresión logística, a pesar de ser uno de los algoritmos de clasificación más simples, sigue siendo altamente relevante debido a su transparencia matemática, eficiencia computacional y capacidad para proporcionar interpretaciones probabilísticas de las predicciones.

En este trabajo, se propone una implementación de un modelo de regresión logística. Nuestra metodología incluye un análisis exploratorio de datos (EDA) detallado para

identificar y justificar la selección de las características más relevantes, seguido del entrenamiento sistemático de modelos de regresión logística bajo múltiples configuraciones de hiperparámetros. Los modelos se evalúan utilizando métricas estándar de clasificación, y sus desempeños se comparan para identificar la configuración que mejor equilibre la precisión predictiva y la capacidad de generalización. Este enfoque no solo demuestra la aplicabilidad de la regresión logística en un escenario práctico, sino que también destaca el papel del ajuste de hiperparámetros y la validación para garantizar resultados de clasificación robustos.

El resto de este documento presentará los pasos realizados a lo largo del proyecto, incluyendo la descarga del conjunto de datos, la lectura del dataset, el análisis de sus características, la división del conjunto de datos, la implementación de la regresión logística y, por último, el análisis de resultados.

## II. DESCARGA DEL CONJUNTO DE DATOS

El primer paso consiste en obtener el dataset desde la plataforma Kaggle, el cual contiene información de diferentes características de vinos rojos específicamente y diferentes características de estos que ayudarán a definir si se pueden considerar buenos o malos. Se descarga el dataset en la computadora vía código (gracias a biblioteca kagglehub) y se almacena la ruta en una variable path para su uso posteriormente.

## III. LECTURA DEL DATASET

En esta etapa se carga el dataset en un DataFrame y, a continuación, se explora su estructura. Se identifica que el dataset contiene 1,599 filas y 12 columnas, con todas sus variables de tipo numérico. Además, se calculan estadísticas descriptivas como la media, la desviación estándar, y los valores mínimos y máximos. Para este trabajo se eligen las 6 features más relevantes para su análisis posterior; la selección se realiza mediante dos métodos: **Univariate Selection** y **Feature Importance**.

En la Tabla I se presenta una primera aproximación a la distribución de los datos de las 6 features elegidas.

## IV. ANÁLISIS DE CARACTERÍSTICAS

El análisis exploratorio se realizó mediante visualizaciones y estadísticas para comprender las relaciones entre las variables predictoras y el objetivo quality. Se elaboraron histogramas (ver Fig. 1) y boxplots (ver Fig. 2), los cuales

TABLE I  
ESTADÍSTICAS DESCRIPTIVAS DEL DATASET

|       | Total sulfur dioxide | Free sulfur dioxide | Alcohol     | Fixed acidity | Volatile Acidity | Citric Acidity |
|-------|----------------------|---------------------|-------------|---------------|------------------|----------------|
| count | 1599.000000          | 1599.000000         | 1599.000000 | 1599.000000   | 1599.000000      | 1599.000000    |
| mean  | 46.467792            | 15.874922           | 10.422983   | 8.319637      | 0.527821         | 0.270976       |
| std   | 32.895324            | 10.460157           | 1.065668    | 1.741096      | 0.179060         | 0.194801       |
| min   | 6.000000             | 1.000000            | 8.400000    | 4.600000      | 0.120000         | 0.000000       |
| 25 %  | 22.000000            | 7.000000            | 9.500000    | 7.100000      | 0.390000         | 0.090000       |
| 50 %  | 38.000000            | 14.000000           | 10.200000   | 7.900000      | 0.520000         | 0.260000       |
| 75 %  | 62.000000            | 21.000000           | 11.100000   | 9.200000      | 0.640000         | 0.420000       |
| max   | 289.000000           | 72.000000           | 14.900000   | 15.900000     | 1.580000         | 1.000000       |

evidencian distribuciones sesgadas a la derecha y la presencia de valores extremos, especialmente en total sulfur dioxide y free sulfur dioxide.

Asimismo, se construyó una matriz de correlación con mapa de calor (ver Fig. 3) para identificar la asociación entre las variables y el objetivo. En síntesis, alcohol presenta la mayor relación con quality 48 %, mientras que free sulfur dioxide muestra la menor 5 %.

Para la detección de outliers se utiliza el método del rango intercuartílico (IQR). Para su tratamiento, se aplicó la técnica de winsorización después de realizar la división del conjunto de datos.

## V. DIVISIÓN DEL DATASET

El conjunto de datos se dividió en tres subconjuntos: 70 % para entrenamiento, 15 % para validación y 15 % para prueba. Para realizar esta partición se aplicó la estrategia de muestreo estratificado (stratified sampling), en el cual el conjunto de datos se organizó en estratos definidos a partir de la variable a predecir. A partir de cada estrato se seleccionaron muestras de forma proporcional para entrenamiento, validación y prueba. Este procedimiento asegura que la distribución de la variable objetivo se conserve en cada subconjunto, lo cual reduce sesgos y brinda mayor representatividad.

## VI. IMPLEMENTACIÓN DE REGRESIÓN LOGÍSTICA

En esta etapa se implementó un modelo de regresión logística, con el objetivo de predecir la calidad del vino a partir de las características seleccionadas. A diferencia de la regresión lineal, la regresión logística modela la probabilidad de pertenencia a una clase mediante la función sigmoide, lo que permite realizar clasificación binaria (vino de buena o mala calidad).




Fig. 1. Histogramas de cada feature




Fig. 2. Boxplots

El entrenamiento del modelo consistió en ajustar los parámetros de manera que la función de pérdida se minimizara. La función de pérdida seleccionada fue la entropía cruzada binaria. Esta función cuantifica la disonancia entre las probabilidades predichas por el modelo y las etiquetas reales, de modo que una menor pérdida indica una mejor correspondencia entre predicción y realidad.

Durante el proceso de entrenamiento, los parámetros del modelo se actualizaron iterativamente siguiendo la dirección opuesta al gradiente de la función de pérdida. Aunque siempre se llegaba a un valor mínimo similar, se estuvo monitoreando que no se cayera en overfitting.

## VII. EVALUACIÓN DEL MODELO

Con la implementación de la regresión logística se procedió a la evaluación del modelo, aplicando el análisis a los resultados de las diez corridas. En general, se observan curvas de entrenamiento y validación que descienden de forma sostenida y con una brecha pequeña entre ambas, lo que indica buena generalización; no se aprecian signos notorios de *overfitting* ni *underfitting*. En algunas corridas se presentan oscilaciones durante las primeras épocas, típicas del arranque del optimizador (ver Fig. 4).

La tabla de comparación de métricas (ver Fig. 5) muestra que el mejor AUC se obtiene con  $\text{lr}=0.03$  y 3000 épocas. La *accuracy*, por su parte, toma valores muy similares en las distintas corridas. Se observa un *recall* bajo en general, una *precision* razonable (aproximadamente 0.86) en configuraciones con  $\text{lr}=0.01$  y un F1-score moderado con un máximo de 0.37.




Fig. 3. HeatMap




Fig. 4. Training vs Loss run 8.

|   | lr       | epochs | val_loss | accuracy | precision | recall   | f1       | auc      |
|---|----------|--------|----------|----------|-----------|----------|----------|----------|
| 0 | 0.030000 | 3000   | 0.269885 | 0.883333 | 0.750000  | 0.187500 | 0.300000 | 0.877855 |
| 1 | 0.030000 | 2000   | 0.278176 | 0.887500 | 0.857143  | 0.187500 | 0.307692 | 0.865084 |
| 2 | 0.030000 | 1000   | 0.278402 | 0.887500 | 0.857143  | 0.187500 | 0.307692 | 0.864032 |
| 3 | 0.010000 | 3000   | 0.279883 | 0.887500 | 0.857143  | 0.187500 | 0.307692 | 0.861929 |
| 4 | 0.003000 | 3000   | 0.291070 | 0.879167 | 0.800000  | 0.125000 | 0.216216 | 0.849609 |
| 5 | 0.010000 | 2000   | 0.299937 | 0.870833 | 0.666667  | 0.062500 | 0.114286 | 0.836238 |
| 6 | 0.003000 | 1500   | 0.310719 | 0.866667 | 0.500000  | 0.031250 | 0.058824 | 0.822266 |
| 7 | 0.001000 | 3000   | 0.326311 | 0.866667 | 0.000000  | 0.000000 | 0.000000 | 0.798377 |
| 8 | 0.010000 | 1000   | 0.328852 | 0.866667 | 0.000000  | 0.000000 | 0.000000 | 0.793870 |
| 9 | 0.001000 | 1500   | 0.369497 | 0.866667 | 0.000000  | 0.000000 | 0.000000 | 0.678335 |

Fig. 5. Cuadro comparativo de Trainings

## VIII. ANÁLISIS DE RESULTADOS

En el análisis de resultados se determinó cuál fue la mejor configuración de entrenamiento: la corrida 10, con  $lr=0.03$  y 3000 épocas. Para verificarla, se evaluó en el conjunto de prueba mediante una matriz de confusión (ver Fig. 6), cuyos resultados muestran una exactitud y una precisión elevadas; es decir, el modelo acierta en la mayoría de los casos. No obstante, el *recall* es bajo, lo que implica que aún se escapan varios positivos.

revisaron los gráficos de dispersión entre valores reales y predicciones, así como los de residuos frente a predicciones, tanto para el muestreo aleatorio como para el estratificado. En ambos casos, las predicciones se alinean con la diagonal de referencia (ver Fig. ?? y Fig. ??), lo que indica un buen ajuste del modelo. Los residuos se distribuyen alrededor de cero sin patrones claros (ver Fig. ?? y Fig. ??), lo que sugiere que los errores son principalmente ruido y que el modelo generaliza adecuadamente. Aunque los dos métodos producen resultados similares, el muestreo estratificado asegura que cada conjunto mantenga la distribución del objetivo, lo que refuerza la representatividad de la evaluación.




Fig. 6. Matriz de confusión

## REFERENCES

- [1] S. Pacheco, "Regresión Logística," Presentación, Instituto Tecnológico de Costa Rica, 2025.

- [2] S. Pacheco, "Metricas," Presentación, Instituto Tecnológico de Costa Rica, 2025.
- [3] "Feature Selection Techniques in Machine Learning," Kaggle, 2020. [Online]. Available: <https://www.kaggle.com/code/piyushagni5/feature-selection-techniques-in-machine-learning>